

Tugas Besar 1 IF3270 Pembelajaran Mesin

Feedforward Neural Network



Disusun oleh:

Filbert	13522021
Benardo	13522055
William Glory Henderson	13522113

SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG

2024

BAB I

DESKRIPSI MASALAH

Tugas Besar 1 IF3270 Pembelajaran Mesin bertujuan memberikan pemahaman mendalam mengenai implementasi Feedforward Neural Network (FFNN) secara menyeluruh dari nol menggunakan bahasa Python. Dalam tugas ini, mahasiswa ditugaskan untuk mengembangkan sebuah modul FFNN yang fleksibel, yang mampu menerima konfigurasi jaringan dengan jumlah neuron dan layer yang bervariasi, serta dapat menggunakan berbagai fungsi aktivasi seperti Linear, ReLU, Sigmoid, tanh, dan Softmax. Selain itu, modul tersebut harus dapat menangani berbagai fungsi loss, seperti Mean Squared Error, Binary Cross-Entropy, dan Categorical Cross-Entropy, serta menerapkan metode inisialisasi bobot yang beragam (zero, distribusi uniform, dan distribusi normal) dengan parameter yang dapat diatur untuk reproducibility. Model yang dihasilkan juga diwajibkan untuk menyimpan bobot dan gradien tiap neuron, menyediakan visualisasi struktur jaringan dan distribusi bobot/gradien, serta menerapkan mekanisme update bobot menggunakan gradient descent. Eksperimen harus dilakukan untuk menganalisis pengaruh hyperparameter seperti depth, width, fungsi aktivasi, learning rate, metode inisialisasi bobot, dan penerapan regularisasi (L1 dan L2) serta normalisasi (misalnya RMSNorm) terhadap performa model, termasuk perbandingan hasil prediksi dengan implementasi dari library seperti sklearn MLPClassifier. Dengan demikian, tugas ini tidak hanya menuntut pemahaman teoritis mengenai jaringan syaraf tiruan, tetapi juga kemampuan praktis dalam mengimplementasikan dan menganalisis model FFNN secara komprehensif.

BAB II

PEMBAHASAN

2.1 Penjelasan Implementasi

2.1.1 Deskripsi kelas beserta deskripsi atribut dan methodnya

1. Kelas ffn

Kelas ini berisi tentang bagaimana cara kerja algoritma feed forward neural network yang meliputi forward propagation dan backward propagation. Kelas ini dapat memakai berbagai fungsi aktivasi, metode inisialisasi bobot, regularisasi (L1 atau L2) serta optional penerapan RMSNorm. Berikut adalah rincian atribut dan method yang terdapat pada kelas ini:

Atribut:

- **layers:** Daftar yang menentukan jumlah neuron pada setiap layer (misalnya: [784, 128, 10]).
- **activations:** Daftar fungsi aktivasi yang digunakan di tiap layer (kecuali input layer), seperti sigmoid, relu, dll.
- **loss_func:** Fungsi loss yang digunakan untuk menghitung kesalahan prediksi.
- **loss_grad:** Turunan dari fungsi loss untuk perhitungan gradien.
- **init_method:** Fungsi yang digunakan untuk menginisialisasi bobot jaringan.
- **init_params:** Parameter tambahan untuk metode inisialisasi bobot yang disediakan dalam bentuk dictionary.
- **reg_type:** Jenis regularisasi yang diterapkan (misalnya 'L1' atau 'L2') atau None jika tidak ada.
- **lambda_reg:** Nilai hyperparameter untuk regularisasi.
- **use_rmsnorm:** Boolean yang menentukan apakah RMSNorm diterapkan pada layer tersembunyi.

- **weights:** List yang menyimpan bobot untuk setiap koneksi antar neuron.
- **biases:** List yang menyimpan bias untuk tiap layer.
- **gradients:** Dictionary yang menyimpan gradien dari bobot dan bias untuk setiap layer.
- **gamma dan gamma_grad (opsional):** Parameter dan gradien yang digunakan untuk RMSNorm pada layer tersembunyi.

Method:

- **__init__(layers, activations, loss_func, loss_grad, init_method, init_params, reg_type, lambda_reg, use_rmsnorm):** Konstruktor yang menginisialisasi semua atribut, bobot, bias, dan (jika diaktifkan) parameter RMSNorm berdasarkan konfigurasi jaringan yang diberikan.
- **forward(X):** Melakukan forward propagation melalui jaringan dengan menghitung nilai input (z) dan output (a) untuk setiap layer, serta menerapkan RMSNorm jika diaktifkan.
- **rms_norm(x, gamma, eps=1e-8):** Menerapkan normalisasi RMS pada input yang diberikan dengan parameter gamma dan epsilon sebagai nilai penstabil.
- **backward(X, y):** Melakukan backward propagation untuk menghitung gradien loss terhadap bobot dan bias, termasuk propagasi melalui RMSNorm jika diperlukan.
- **update_weights(learning_rate):** Mengupdate bobot, bias, dan parameter gamma (jika RMSNorm aktif) berdasarkan gradien yang telah dihitung dan laju pembelajaran yang diberikan.
- **calculate_loss(X, y):** Menghitung nilai loss dari prediksi, serta menambahkan biaya regularisasi jika diterapkan.
- **train(X_train, y_train, X_val, y_val, batch_size, epochs, learning_rate, verbose):** Melatih jaringan dengan melakukan pembaruan bobot secara iteratif berdasarkan batch data, serta menyimpan history loss untuk data pelatihan dan validasi.

- **display_model_graph(max_neurons_per_layer, node_size, weight_precision, min_display_value):** Menampilkan visualisasi grafis dari struktur jaringan, termasuk representasi neuron, bobot, gradien, dan bias menggunakan pustaka networkx dan matplotlib.
 - **plot_weight_and_gradient_distribution(layers_to_plot):** Menampilkan histogram distribusi bobot dan gradien untuk layer yang dipilih, sehingga membantu dalam analisis pembelajaran jaringan.
 - **save_model(filename):** Menyimpan model dan seluruh state atributnya ke dalam file menggunakan modul pickle.
 - **load_model(filename):** Memuat model yang telah disimpan dari file dan mengembalikan state atribut jaringan.
2. Fungsi aktivasi, fungsi loss, dan inisialisasi bobot dibuat tidak dalam bentuk kelas tetapi dalam bentuk method saja untuk setiap fungsinya. Untuk algoritmanya disesuaikan sesuai dengan rumus aslinya.

2.1.2 Penjelasan Forward Propagation

Forward propagation adalah proses mengalirkan atau meneruskan data input melalui setiap jaringan neural (hidden layer) untuk menghasilkan output akhir. Pada kelas **FFNN**, proses ini dimulai dengan memasukkan data input (X) sebagai aktivasi awal. Setiap layer kemudian menghitung nilai pre-aktivasi (z) dengan mengalikan aktivasi dari layer sebelumnya dengan bobot yang sesuai dan menambahkan bias. Berikut adalah poin-poin utama mengenai forward propagation dalam kelas ini:

- **Inisialisasi Input:** Proses dimulai dengan menyimpan input X sebagai aktivasi awal (a_values).
- **Perhitungan Nilai z:** Untuk setiap layer, nilai z dihitung sebagai perkalian dot antara aktivasi layer sebelumnya dengan bobot (W) ditambah bias (b), yaitu: $z = a \cdot W + b$.

- **Penerapan RMSNorm (opsional):** Jika opsi RMSNorm aktif dan layer tersebut merupakan layer tersembunyi, nilai z awal disimpan, kemudian dinormalisasi dengan menggunakan parameter γ untuk menstabilisasi distribusi nilai.
- **Fungsi Aktivasi:** Setelah mendapatkan nilai z (atau nilai yang telah dinormalisasi), fungsi aktivasi yang telah didefinisikan (misalnya sigmoid, relu, atau tanh) diterapkan untuk menghasilkan output aktivasi baru yang kemudian akan menjadi input bagi layer selanjutnya.
- **Penyimpanan Nilai:** Selama proses ini, nilai pre-aktivasi (z_values) dan nilai aktivasi (a_values) disimpan, yang kemudian dapat digunakan pada tahap backward propagation untuk perhitungan gradien.

Proses ini diulangi untuk setiap layer hingga mencapai layer output. Hasil akhir merupakan prediksi atau output dari jaringan. Forward propagation mengubah input menjadi output dengan melalui beberapa proses perhitungan dan setiap langkah membantu jaringan untuk belajar memodelkan hubungan antara data input dan output yang diinginkan.

2.1.3 Penjelasan Backward Propagation

Backward propagation atau backpropagation adalah proses membalikan alur data pada jaringan neural untuk mengetahui seberapa besar kontribusi setiap bobot dan bias dalam menghasilkan kesalahan (loss) pada output. Proses ini digunakan untuk memperbarui parameter-parameter jaringan agar hasil prediksi dapat menjadi lebih akurat. Berikut adalah poin-poin mengenai backward propagation dalam kelas ini:

- **Perhitungan Error Awal (Delta)**

Pertama, dilakukan forward propagation untuk mendapatkan prediksi output dari jaringan berdasarkan input. Kemudian, fungsi turunan loss digunakan untuk menghitung error awal, yang disimpan dalam variabel δ . Error ini

mewakili perbedaan antara prediksi dan nilai sebenarnya (selisih antara output jaringan dan nilai yang seharusnya).

- **Iterasi dari Output ke Input (Belakang ke Depan)**

Proses backward propagation dilakukan dengan iterasi dari layer output ke layer input (dengan menggunakan loop terbalik). Di setiap layer, kita gunakan error (delta) yang sudah ada untuk menghitung seberapa banyak kontribusi tiap neuron terhadap kesalahan. Selain itu, kita juga menghitung gradien untuk bobot dan bias di layer tersebut.

- **Menggunakan Turunan Fungsi Aktivasi**

Pada setiap layer, fungsi aktivasi yang digunakan dapat berbeda-beda sesuai dengan input pengguna. Nilai **delta** dikalikan dengan turunan fungsi aktivasi yang digunakan di layer tersebut. Fungsi turunan membantu menentukan seberapa besar perubahan output disebabkan oleh perubahan input z (hasil dari perkalian bobot dan penambahan bias). Jika fitur RMSNorm diaktifkan, prosesnya akan menjadi sedikit berbeda. Turunan fungsi aktivasi dihitung berdasarkan nilai setelah RMSNorm dan gradien untuk parameter gamma dihitung serta error delta disesuaikan agar memperhitungkan efek normalisasi.

- **Menghitung Gradien untuk Bobot dan Bias**

Setelah mendapatkan turunan fungsi aktivasi, gradien untuk bobot dihitung dengan mengalikan transposisi dari aktivasi layer sebelumnya dengan nilai delta. Gradien untuk bias dihitung dengan menjumlahkan semua nilai delta pada layer tersebut dan dibagi dengan jumlah sampel.

- **Penambahan Regularisasi (Opsional) dan Perlakuan Khusus untuk RMSNorm (Opsional)**

Jika regularisasi (L1 atau L2) digunakan, gradien bobot ditambahkan dengan nilai penalti yang sesuai untuk mengubah bobot yang terlalu besar sehingga membantu mencegah overfitting. Sementara itu, jika RMSNorm aktif di

hidden layer, perhitungannya sedikit berbeda. Selain menghitung gradien untuk bobot dan bias, jaringan juga menghitung gradien untuk parameter gamma yang digunakan dalam proses normalisasi.

- **Propagasi Error ke Layer Sebelumnya**

Setelah gradien untuk bobot dan bias dihitung di sebuah layer, error delta dihitung kembali untuk layer sebelumnya dengan mengalikan delta dengan transposisi bobot layer tersebut.

Proses ini terus berlanjut hingga mencapai layer input. Backward propagation membantu menentukan arah perbaikan pada setiap parameter dalam jaringan. Dengan mengetahui gradien dari setiap bobot dan bias, kita dapat mengupdate parameter tersebut secara bertahap untuk meminimalkan kesalahan prediksi jaringan.

2.2 Hasil Pengujian

2.2.1 Pengaruh Depth dan Width

Dalam konteks FFNN, depth dan width adalah dua aspek utama yang mendefinisikan arsitektur jaringan. Depth mengacu pada jumlah layer—terutama jumlah hidden layer—yang digunakan dalam model. Semakin banyak hidden layer, model dapat melakukan transformasi data secara bertahap dan membangun representasi hierarkis dari fitur, mulai dari fitur tingkat rendah hingga tingkat abstraksi yang lebih tinggi. Sementara itu, width mengacu pada jumlah neuron yang terdapat dalam satu layer. Lebar layer yang lebih besar memberikan kapasitas yang lebih tinggi untuk menangkap berbagai fitur dalam data mentah, karena lebih banyak neuron dapat memproses dan merepresentasikan variasi informasi secara paralel.

Untuk menguji pengaruh kedua hyperparameter tersebut, eksperimen dilakukan dengan dua pendekatan pengujian:

1. Variasi Width (dengan Depth tetap)

- Eksperimen dilakukan dengan menggunakan satu hidden layer (depth = 1) dengan jumlah neuron yang berbeda-beda, yakni 64, 128, dan 256 neuron.
- Pada tiap konfigurasi, model dilatih dengan parameter yang sama (misalnya batch size, learning rate, dan jumlah epoch) dan kemudian dievaluasi berdasarkan akurasi prediksi dan grafik loss pelatihan serta validasi.

2. Variasi Depth (dengan Width tetap)

- Di sini, eksperimen dilakukan dengan mempertahankan jumlah neuron per layer (misalnya width tetap 64) dan mengubah jumlah hidden layer menjadi 1, 2, dan 3 layer.
- Proses pelatihan dan evaluasi dilakukan serupa, sehingga perbandingan dapat dilakukan berdasarkan akurasi dan tren loss yang diperoleh.

Peningkatan width pada hidden layer menunjukkan dampak yang cukup jelas terhadap kemampuan representasi model. Dari hasil pengujian, ketika width ditetapkan sebesar 64, model memperoleh akurasi sekitar 90,77%. Dengan menaikkan width menjadi 128, akurasi meningkat menjadi 91,28%, dan selanjutnya pada width 256 akurasi mencapai 91,54%. Hal ini mengindikasikan bahwa penambahan neuron dalam satu

hidden layer memungkinkan model untuk menangkap fitur-fitur yang lebih kompleks dan menyimpan informasi secara lebih rinci. Meskipun peningkatan akurasi tidak bersifat linear dan cenderung melambat setelah mencapai ambang tertentu, penambahan width tetap memberikan keuntungan dalam hal kapasitas model, terutama dalam mengolah data mentah yang memiliki variabilitas tinggi.

Di sisi lain, peningkatan depth atau jumlah hidden layer juga memberikan kontribusi positif terhadap performa model, meskipun peningkatannya relatif lebih kecil jika dibandingkan dengan penambahan width. Hasil eksperimen menunjukkan bahwa model dengan 1 hidden layer mencapai akurasi sekitar 90,77%, yang meningkat menjadi 91,29% dengan 2 hidden layer, dan sedikit lagi naik menjadi 91,36% dengan 3 hidden layer. Dengan menambah hidden layer, model dapat membangun representasi hierarkis yang mengubah fitur-fitur dasar pada layer awal menjadi fitur yang lebih abstrak pada layer selanjutnya. Walaupun keuntungan yang diperoleh tidak sebesar peningkatan yang dihasilkan dari penambahan width, penambahan depth membantu model untuk mengorganisir dan memproses transformasi non-linear secara bertahap. Namun, perlu diingat bahwa penambahan depth juga membawa tantangan seperti peningkatan kompleksitas komputasi dan potensi masalah vanishing gradient, sehingga perbaikan performa yang diperoleh cenderung lebih marginal.

Keuntungan penambahan width adalah peningkatan kapasitas representasi yang memungkinkan jaringan menangani data dengan variabilitas tinggi secara lebih efektif. Namun, perlu diperhatikan bahwa menambahkan neuron secara berlebihan dapat menyebabkan model menjadi terlalu besar, yang berpotensi meningkatkan risiko overfitting jika jumlah data pelatihan tidak memadai. Sementara itu, penambahan depth memberikan kemampuan untuk mengorganisasi informasi secara bertingkat dan memproses transformasi non-linear yang kompleks. Akan tetapi, peningkatan depth juga membawa tantangan seperti kompleksitas komputasi yang lebih tinggi dan potensi masalah vanishing gradient, yang dapat menghambat proses pembelajaran jika tidak ditangani dengan benar.

Dengan demikian, eksperimen yang telah dilakukan menunjukkan bahwa kedua aspek width dan depth memberikan kontribusi positif terhadap performa FFNN, namun dengan keuntungan yang berbeda. Peningkatan width cenderung memberikan

peningkatan akurasi yang lebih signifikan karena kapasitas representasi yang lebih besar, sedangkan penambahan depth membantu model dalam mengabstraksi fitur secara bertahap dengan peningkatan performa yang lebih marginal. Pemilihan konfigurasi yang optimal sangat bergantung pada kompleksitas data, ukuran dataset, dan pertimbangan efisiensi komputasi, sehingga eksperimen lebih lanjut diperlukan untuk menemukan keseimbangan terbaik antara kedua hyperparameter tersebut.

Berikut adalah hasil perbandingan akurasi prediksi untuk pengujian variasi width :

```
Melatih model dengan hidden layer width: 64
Model dengan width 64 memperoleh akurasi: 0.9077
Melatih model dengan hidden layer width: 128
Model dengan width 128 memperoleh akurasi: 0.9128
Melatih model dengan hidden layer width: 256
Model dengan width 256 memperoleh akurasi: 0.9154
```

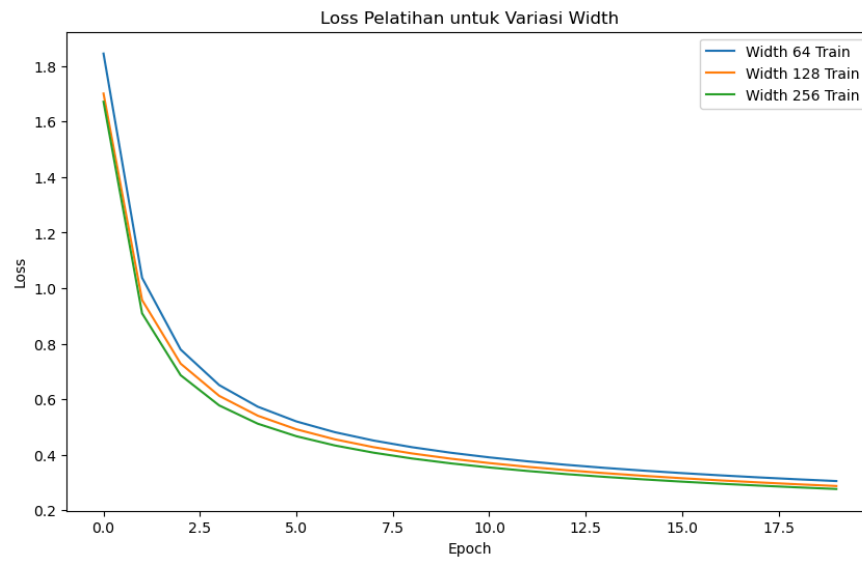
Gambar 2.2.1.1. Perbandingan Hasil Prediksi variasi width

Berikut adalah hasil perbandingan akurasi prediksi untuk pengujian variasi depth :

```
Melatih model dengan 1 hidden layer
Model dengan 1 hidden layer memperoleh akurasi: 0.9077
Melatih model dengan 2 hidden layer
Model dengan 2 hidden layer memperoleh akurasi: 0.9129
Melatih model dengan 3 hidden layer
Model dengan 3 hidden layer memperoleh akurasi: 0.9136
```


Gambar 2.2.1.2. Perbandingan Hasil Prediksi variasi depth

Berikut adalah hasil perbandingan loss pelatihan untuk pengujian variasi width :



Gambar 2.2.1.3. Perbandingan Loss Pelatihan variasi width

Berikut adalah hasil perbandingan loss pelatihan untuk pengujian variasi depth :



Gambar 2.2.1.4. Perbandingan Loss Pelatihan variasi depth

2.2.2 Pengaruh Fungsi Aktivasi

Fungsi aktivasi dalam FFNN merupakan komponen penting yang mengubah output linear dari setiap neuron menjadi representasi non-linear. Dengan kata lain, fungsi aktivasi memperkenalkan non-linearitas ke dalam model sehingga jaringan dapat menangkap pola yang kompleks dalam data. Untuk menguji pengaruh fungsi aktivasi, dilakukan eksperimen dengan mengganti fungsi aktivasi pada hidden layer sambil mempertahankan parameter pelatihan lainnya (seperti `input_dim = 784`, `hidden_dim = 64`, `output_dim = 10`, `epochs = 20`, `batch_size = 32`, dan `learning_rate = 0.01`). Pada pengujian tersebut, hidden layer menggunakan fungsi aktivasi yang berbeda, seperti linear, ReLU, sigmoid, tanh, leaky_relu, dan ELU, sedangkan layer output selalu menggunakan softmax untuk menghasilkan probabilitas kelas. Pengujian dilakukan dengan memantau akurasi prediksi pada data validasi, grafik loss pelatihan dan validasi, serta distribusi bobot dan gradien pada tiap layer.

Hasil eksperimen menunjukkan bahwa model dengan aktivasi linear memperoleh akurasi sekitar 90,36%, sedangkan model dengan aktivasi ReLU mencapai 90,77%, leaky_relu 90,75%, dan ELU 90,58%. Di sisi lain, model yang menggunakan fungsi sigmoid hanya mencapai akurasi sekitar 85,58%, dan tanh menghasilkan akurasi sekitar 89,67%. Di sisi lain, penggunaan fungsi linear, meskipun menghasilkan akurasi moderat sekitar 90,36%, tidak menambahkan non-linearitas pada jaringan; karena jika semua hidden layer menggunakan fungsi linear, maka kombinasi multi-layer tersebut secara matematis ekuivalen dengan model linear tunggal (seperti regresi linear multinomial pada layer softmax), sehingga tidak mampu menangkap pola non-linear kompleks. Pada bagian loss, grafik yang diperoleh dari eksperimen memberikan gambaran yang jelas mengenai seberapa cepat dan stabil model melakukan konvergensi saat menggunakan fungsi aktivasi yang berbeda. Misalnya, model dengan aktivasi berbasis ReLU (termasuk varian leaky_relu dan ELU) menunjukkan tren penurunan loss yang konsisten dan stabil selama pelatihan, yang mengindikasikan bahwa aliran gradien tetap terjaga dengan baik. Hal ini disebabkan oleh fakta bahwa ReLU memberikan gradien konstan (nilai 1) pada input positif, sehingga tidak terjadi masalah vanishing gradient. Sebaliknya, model dengan fungsi sigmoid cenderung menunjukkan penurunan loss yang lebih lambat dan tidak konsisten. Hal ini dapat dijelaskan oleh sifat saturasi sigmoid, di mana output

mendekati 0 atau 1 untuk nilai input yang ekstrim, sehingga gradien yang dihasilkan menjadi sangat kecil. Akibatnya, pembaruan bobot pun menjadi minimal, yang membuat proses konvergensi berjalan lebih lambat dan loss tidak turun secara signifikan.

Selain itu, distribusi bobot dan gradien pada hidden layer juga memberikan gambaran tambahan tentang efektivitas fungsi aktivasi. Model dengan aktivasi ReLU cenderung menghasilkan distribusi bobot yang seimbang dan gradien yang tersebar optimal, sehingga aliran gradien selama backpropagation tidak terhambat. Sebaliknya, pada model dengan fungsi sigmoid, distribusi gradien lebih terkonsentrasi di sekitar nol, yang menunjukkan masalah saturasi di mana nilai output mendekati 0 atau 1 sehingga gradien menjadi sangat kecil. Hal ini mengakibatkan pembelajaran yang lambat dan update bobot yang minimal, yang sejalan dengan akurasi yang lebih rendah. Fungsi tanh, dengan rentang output antara -1 hingga 1 menunjukkan distribusi gradien yang sedikit lebih lebar dibandingkan sigmoid, namun masih belum mampu mengalirkan gradien seefisien keluarga ReLU.

Keunggulan fungsi aktivasi berbasis ReLU terutama terletak pada kemampuannya menghindari masalah vanishing gradient. Pada ReLU, gradien untuk input positif tetap konstan (yaitu 1), sehingga aliran gradien tidak terhambat dan pembelajaran dapat berlangsung lebih efisien. Varian seperti leaky_relu dan ELU juga mendukung aliran gradien dengan mengatasi potensi "dying ReLU" melalui pemberian gradien non-nol pada nilai negatif. Meskipun demikian, pemilihan fungsi aktivasi sangat bergantung pada karakteristik data dan masalah yang dihadapi. Misalnya, jika data memiliki distribusi yang simetris atau jika model diharapkan menangkap nilai negatif secara eksplisit, fungsi tanh mungkin dapat memberikan keuntungan tertentu. Namun, dalam konteks eksperimen yang dilakukan pada dataset MNIST, fungsi aktivasi berbasis ReLU terbukti memberikan kinerja terbaik karena kemampuannya untuk menjaga aliran gradien dan menghindari saturasi.

Secara keseluruhan, hasil pengujian tidak hanya menunjukkan perbedaan dalam akurasi prediksi dan grafik loss, tetapi juga perbedaan yang signifikan pada distribusi bobot dan gradien. Ini menegaskan bahwa fungsi aktivasi mempengaruhi seluruh aspek pembelajaran dalam FFNN, mulai dari kecepatan konvergensi hingga kestabilan pembaruan parameter. Oleh karena itu, pemilihan fungsi aktivasi harus didasarkan pada

eksperimen yang cermat, dengan memperhatikan kondisi data serta kebutuhan spesifik model agar dapat menghasilkan performa yang optimal.

Berikut adalah Hasil Perbandingan Akurasi Hasil Prediksi :

```
Melatih model dengan fungsi aktivasi hidden: linear
Model dengan aktivasi linear memperoleh akurasi: 0.9036

Melatih model dengan fungsi aktivasi hidden: relu
Model dengan aktivasi relu memperoleh akurasi: 0.9077

Melatih model dengan fungsi aktivasi hidden: sigmoid
Model dengan aktivasi sigmoid memperoleh akurasi: 0.8558

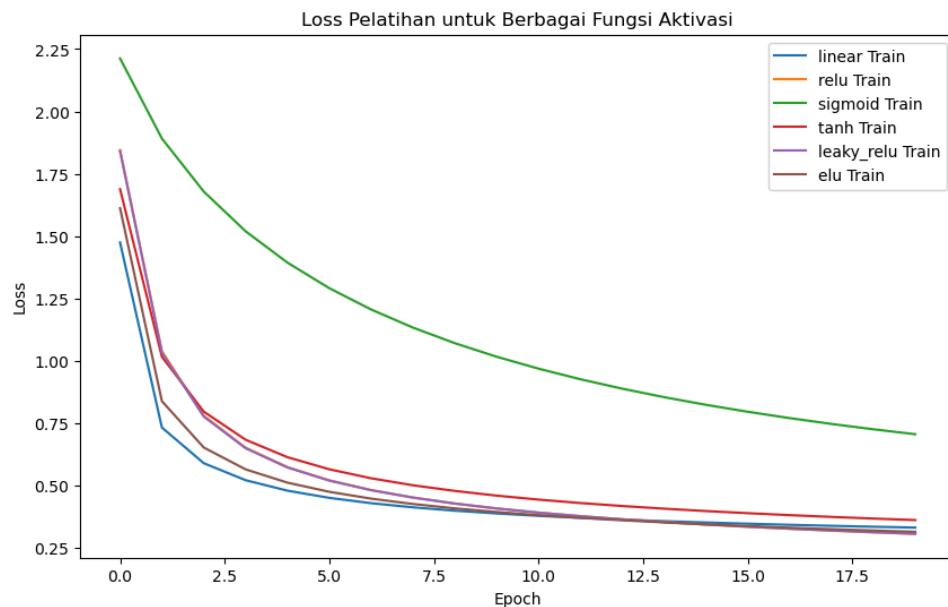
Melatih model dengan fungsi aktivasi hidden: tanh
Model dengan aktivasi tanh memperoleh akurasi: 0.8967

Melatih model dengan fungsi aktivasi hidden: leaky_relu
Model dengan aktivasi leaky_relu memperoleh akurasi: 0.9075

Melatih model dengan fungsi aktivasi hidden: elu
Model dengan aktivasi elu memperoleh akurasi: 0.9058
```


Gambar 2.2.2.1. Perbandingan Hasil Prediksi variasi fungsi aktivasi

Berikut adalah hasil perbandingan loss pelatihan untuk pengujian variasi fungsi aktivasi :




Gambar 2.2.2.2. Perbandingan Loss Pelatihan


Berikut adalah Hasil Perbandingan Distribusi Bobot dan Gradien tiap layer:




Gambar 2.2.2.3. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (linear)




Gambar 2.2.2.4. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (linear)




Gambar 2.2.2.5. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (relu)




Gambar 2.2.2.6. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (relu)



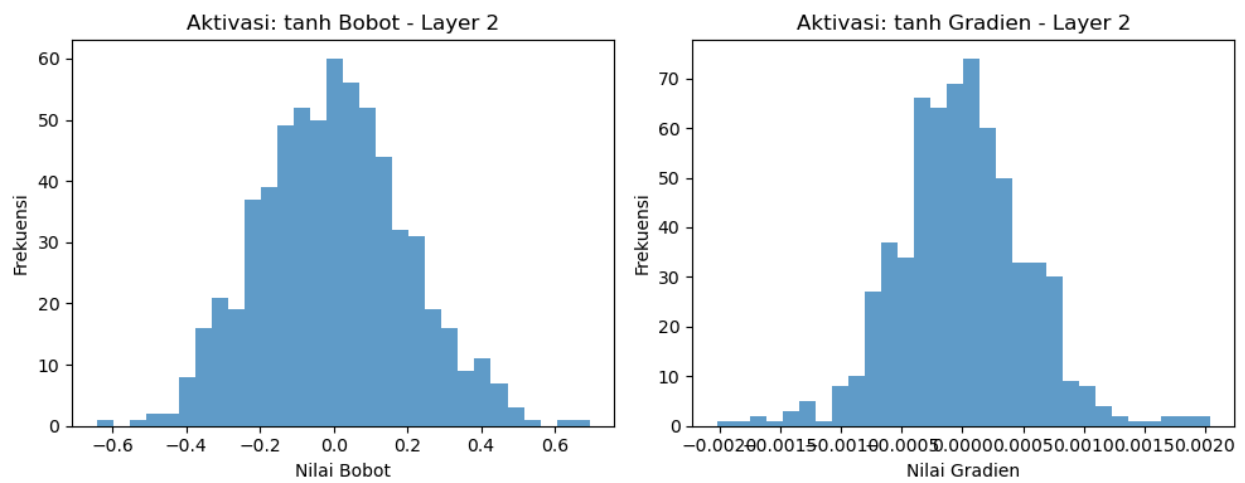
Gambar 2.2.2.7. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (sigmoid)



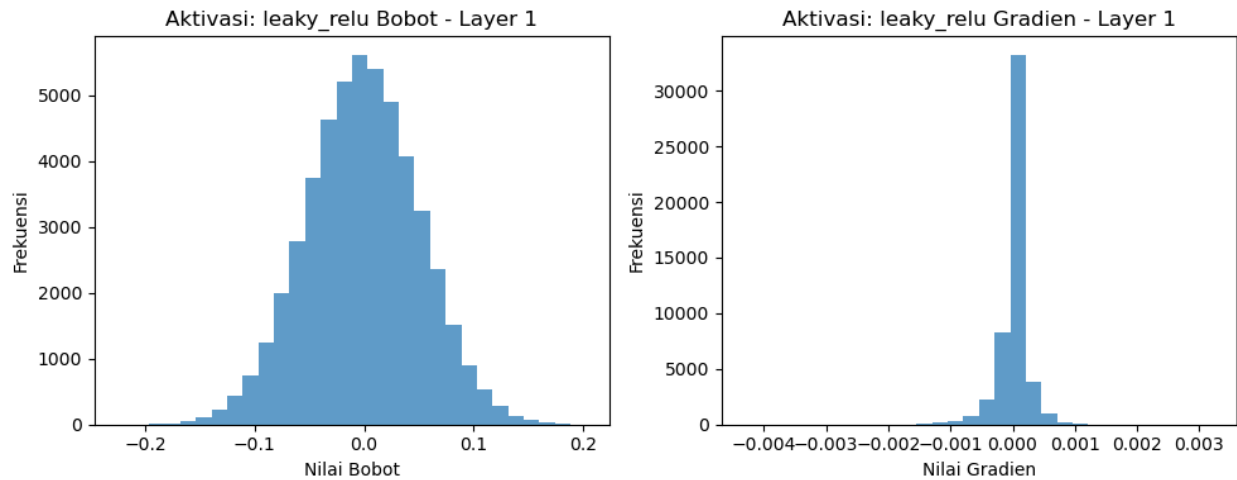
Gambar 2.2.2.8. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (sigmoid)




Gambar 2.2.2.9. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (tanh)




Gambar 2.2.2.10. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (tanh)




Gambar 2.2.2.11. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (leaky_relu)



Gambar 2.2.2.12. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (leaky_relu)



Gambar 2.2.2.13. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (elu)



Gambar 2.2.2.14. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (elu)

2.2.3 Pengaruh learning rate

Learning rate adalah hyperparameter yang menentukan seberapa besar langkah pembaruan bobot (weight update) pada setiap iterasi proses training. Semakin tinggi nilai learning rate, semakin cepat model memperbarui bobotnya, namun risiko overshoot atau ketidakstabilan juga meningkat. Sebaliknya, jika learning rate terlalu kecil, pembaruan bobot berlangsung sangat lambat, sehingga proses konvergensi bisa memakan waktu lama atau bahkan terjebak di local minimum. Untuk menguji pengaruh learning rate pada FFNN, dilakukan eksperimen dengan tiga variasi nilai Learning rate: 0,001; 0,01; dan 0,1. Pada setiap konfigurasi, arsitektur jaringannya tetap sama yaitu $784 \rightarrow 64 \rightarrow 10$ dan parameter pelatihan lain (batch size = 32, epochs = 20) dipertahankan agar perbandingan menjadi adil.

Hasil pengujian menunjukkan bahwa model dengan learning rate 0,001 hanya mencapai akurasi sekitar 76,07%, sedangkan pada learning rate 0,01 akurasi meningkat signifikan menjadi 90,77%. Menariknya, ketika Learning rate dinaikkan lebih jauh menjadi 0,1, model justru mencapai akurasi tertinggi, yaitu 95,30%. Meski pada umumnya learning rate yang terlalu besar berpotensi menyebabkan loss berosilasi atau gagal konvergen, dalam kasus ini Learning rate = 0,1 tampaknya masih berada dalam rentang stabil untuk dataset MNIST, sehingga memberikan kecepatan konvergensi yang tinggi dan akurasi akhir yang terbaik. Dari grafik loss pelatihan dan validasi, terlihat bahwa Learning rate yang terlalu kecil (0,001) membuat penurunan loss berjalan lambat,

sementara Learning rate yang lebih besar (0,01 dan 0,1) menurunkan loss dengan lebih cepat dan stabil.

Selain melihat akurasi dan loss, analisis distribusi bobot dan gradien juga memperkuat temuan tersebut. Pada Learning rate yang rendah (0,001), gradien cenderung kecil, sehingga update bobot pun minimal. Hal ini tercermin dari histogram gradien yang relatif terkonsentrasi di sekitar nol yang menandakan pembelajarannya lebih lambat. Ketika Learning rate lebih besar, seperti 0,01 atau 0,1, distribusi gradien menjadi lebih luas, yang mengindikasikan update bobot lebih signifikan dan proses pembelajaran yang lebih agresif. Namun, jika Learning rate terlalu besar, model bisa saja mengalami overshoot dan sulit mencapai konvergensi yang stabil. Untungnya, pada eksperimen ini Learning rate = 0,1 masih cukup stabil sehingga menghasilkan akurasi yang lebih tinggi.

Secara keseluruhan, hasil eksperimen menegaskan pentingnya pemilihan learning rate yang tepat. Learning rate terlalu kecil (0,001) membuat proses training berjalan sangat lambat dan menahan pencapaian akurasi yang optimal. Learning rate sedang (0,01) sudah cukup efektif untuk mencapai akurasi yang layak, sedangkan learning rate lebih besar (0,1) justru membawa model ke performa terbaik pada dataset MNIST ini. Meskipun demikian, pemilihan learning rate ideal tetap kontekstual dan sangat tergantung pada karakteristik data serta arsitektur model.

Berikut adalah Hasil Perbandingan Akurasi Hasil Prediksi :

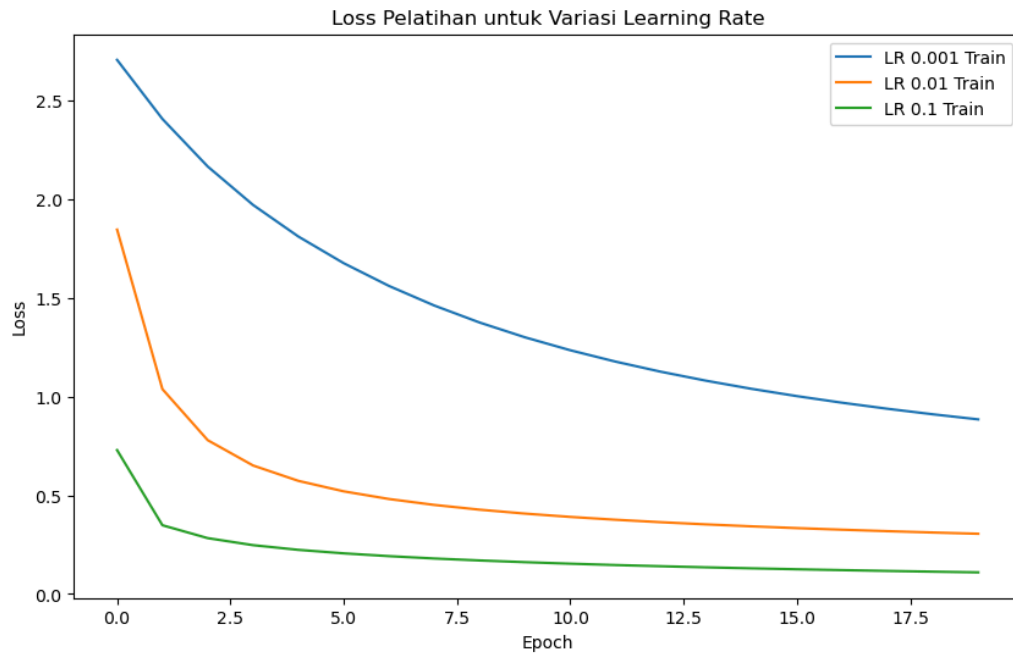
```
Melatih model dengan learning rate: 0.001
Model dengan learning rate 0.001 memperoleh akurasi: 0.7607

Melatih model dengan learning rate: 0.01
Model dengan learning rate 0.01 memperoleh akurasi: 0.9077

Melatih model dengan learning rate: 0.1
Model dengan learning rate 0.1 memperoleh akurasi: 0.9530
```


Gambar 2.2.3.1. Perbandingan Hasil Prediksi variasi learning rate

Berikut adalah hasil perbandingan loss pelatihan untuk pengujian variasi learning rate :

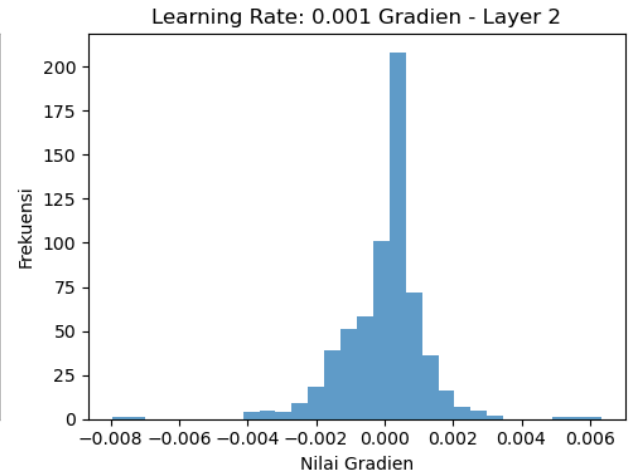



Gambar 2.2.3.2. Perbandingan Loss Pelatihan



Berikut adalah Hasil Perbandingan Distribusi Bobot dan Gradien tiap layer:





Gambar 2.2.3.3. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (bobot 0.001)




Gambar 2.2.3.4. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (bobot 0.001)




Gambar 2.2.3.5. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (bobot 0.01)



Gambar 2.2.3.6. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (bobot 0.01)



Gambar 2.2.3.7. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (bobot 0.1)



Gambar 2.2.3.8. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (bobot 0.01)

2.2.4 Pengaruh inisialisasi bobot

Inisialisasi bobot merupakan salah satu komponen fundamental dalam FFNN. Secara umum, inisialisasi bobot bertujuan untuk menentukan nilai awal dari setiap bobot dalam jaringan sebelum proses training dimulai. Nilai awal tersebut sangat berpengaruh terhadap bagaimana sinyal dan gradien mengalir melalui jaringan, serta pada seberapa cepat dan stabil proses konvergensi selama pembelajaran. Jika inisialisasi dilakukan dengan cara yang tidak tepat misalnya, semua bobot diinisialisasi dengan nol maka jaringan tidak dapat memecah simetri antar neuron, sehingga setiap neuron menghasilkan output yang identik dan tidak ada variasi yang memungkinkan jaringan untuk belajar pola

yang berbeda dari data. Oleh karena itu, metode inisialisasi yang baik harus mampu memberikan sebaran nilai bobot yang optimal agar masing-masing neuron dapat bekerja secara independen dan mendukung aliran gradien yang stabil dan bisa menghindari masalah vanishing atau exploding gradient.

Untuk menguji pengaruh metode inisialisasi bobot, dilakukan eksperimen pada arsitektur yang sama ($784 \rightarrow 64 \rightarrow 10$) dengan parameter pelatihan yang konstan (epochs = 20, batch_size = 32, learning_rate = 0.01) dan fungsi aktivasi ReLU di hidden layer serta softmax di output layer.

Beberapa metode inisialisasi yang diuji meliputi:

- **Zero Initialization:** Menginisialisasi semua bobot dengan nol.
- **Uniform Initialization:** Mengambil bobot dari distribusi seragam (misalnya, dari interval $[-0.5, 0.5]$).
- **Normal Initialization:** Mengambil bobot dari distribusi normal dengan mean 0 dan variance tertentu (misalnya, 0.1).
- **He Initialization:** Menggunakan $N(0, \sqrt{2/fan_in})$, dirancang khusus untuk fungsi aktivasi ReLU.
- **Xavier Uniform/Normal Initialization:** Menghitung varians berdasarkan fan_in dan fan_out untuk menjaga kestabilan sinyal antar layer.

Hasil eksperimen menunjukkan perbandingan yang cukup mencolok. Model dengan zero initialization gagal memecah simetri antar neuron, menghasilkan akurasi hanya sekitar 11,43%. Sementara itu, model yang menggunakan uniform dan normal initialization memperoleh akurasi sekitar 83,30% dan 82,66% secara berturut-turut, yang menunjukkan kemampuan belajar yang jauh lebih baik daripada zero initialization, namun masih belum optimal. Di sisi lain, model dengan He initialization mencapai akurasi sekitar 90,77%, sedangkan model dengan Xavier Uniform dan Xavier Normal memperoleh akurasi masing-masing sekitar 91,09% dan 90,77%. Perbandingan hasil akhir prediksi ini menunjukkan bahwa metode inisialisasi yang didesain khusus untuk mempertahankan varians, seperti He dan Xavier, memberikan keuntungan dalam hal performa model. Hal ini terutama disebabkan oleh kesesuaian metode tersebut dengan fungsi aktivasi ReLU yang digunakan, di mana He initialization secara khusus dirancang untuk mengatasi potensi masalah vanishing gradient dengan mengatur varians bobot

sebesar $2/\text{fan_in}$, sehingga menjaga aliran sinyal dan gradien tetap stabil pada setiap layer. Sementara itu, Xavier initialization menjaga keseimbangan antara fan_in dan fan_out sehingga varians sinyal tetap konsisten dari input hingga output, yang juga sangat mendukung kinerja ReLU dalam menghindari saturasi yang berlebihan.

Selain akurasi akhir, grafik loss pelatihan dan validasi juga memberikan informasi penting. Model yang diinisialisasi dengan metode He dan Xavier menunjukkan penurunan loss yang lebih cepat dan stabil dibandingkan dengan model yang menggunakan uniform atau normal initialization. Hal ini mengindikasikan bahwa nilai awal bobot yang optimal membantu jaringan untuk melakukan pembaruan parameter secara efisien dan mencegah terjadinya fluktuasi loss yang besar selama proses training.

Lebih jauh lagi, analisis distribusi bobot dan gradien dari beberapa layer juga mengungkapkan perbedaan karakteristik antar metode inisialisasi. Pada zero initialization, histogram bobot dan gradien terkonsentrasi di angka nol, menandakan tidak adanya perbedaan nilai yang dapat memicu pembelajaran. Sementara itu, uniform dan normal initialization memberikan sebaran yang lebih lebar, namun distribusinya belum ideal untuk mendukung fungsi aktivasi ReLU, sehingga beberapa neuron mungkin beroperasi di daerah saturasi. Metode He dan Xavier, di sisi lain, menghasilkan distribusi bobot yang lebih terpusat namun dengan varians yang cukup untuk menjaga nilai aktivasi agar tidak terlalu kecil atau terlalu besar, sehingga mendukung aliran gradien yang optimal dan mencegah terjadinya vanishing gradient. Dengan demikian, distribusi bobot dan gradien yang optimal ini mendukung proses konvergensi model dan menghasilkan performa akhir yang lebih baik.

Secara keseluruhan, pengaruh inisialisasi bobot sangat besar terhadap performa FFNN. Metode inisialisasi yang tepat seperti He dan Xavier mampu memberikan nilai awal yang mendukung aliran sinyal dan gradien yang stabil, sehingga model dapat belajar dengan cepat dan efektif, menghasilkan akurasi yang tinggi serta loss yang menurun secara konsisten. Sebaliknya, metode yang tidak tepat, seperti zero initialization, akan menghambat pembelajaran secara drastis. Perbandingan hasil prediksi, grafik loss, dan distribusi bobot/gradien yang diperoleh dari eksperimen ini menegaskan bahwa pemilihan metode inisialisasi harus disesuaikan dengan karakteristik arsitektur dan fungsi aktivasi yang digunakan agar model dapat mencapai performa optimal.

Berikut adalah Hasil Perbandingan Akurasi Hasil Prediksi :

```
Melatih model dengan inisialisasi bobot: zero
Model dengan inisialisasi zero memperoleh akurasi: 0.1143

Melatih model dengan inisialisasi bobot: uniform
Model dengan inisialisasi uniform memperoleh akurasi: 0.8330

Melatih model dengan inisialisasi bobot: normal
Model dengan inisialisasi normal memperoleh akurasi: 0.8266

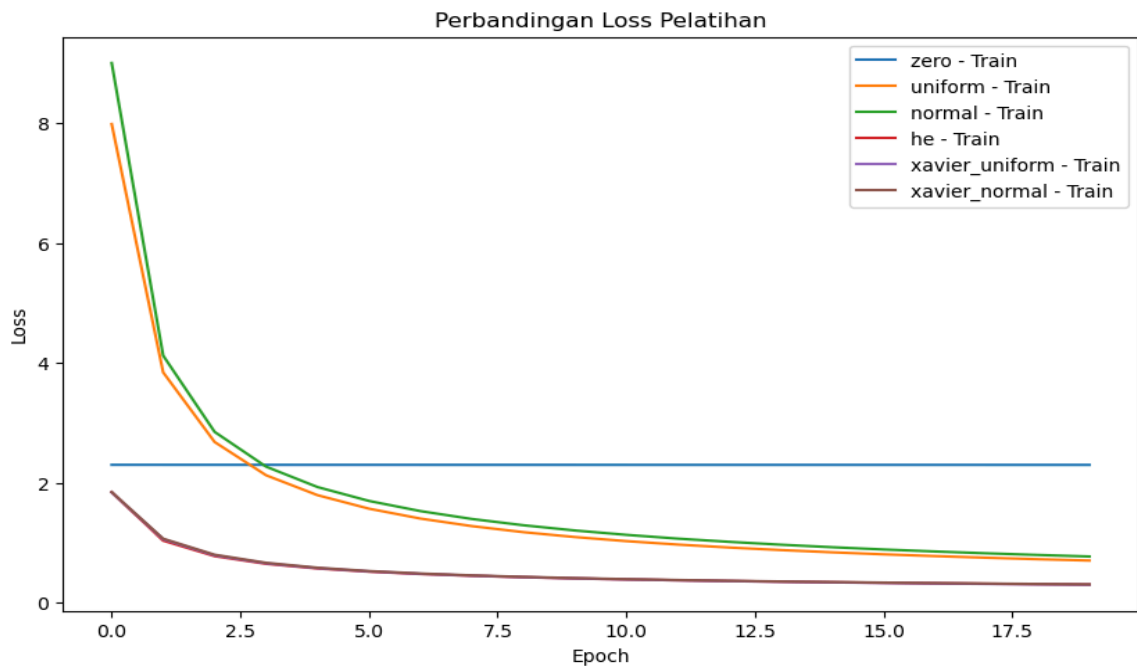
Melatih model dengan inisialisasi bobot: he
Model dengan inisialisasi he memperoleh akurasi: 0.9077

Melatih model dengan inisialisasi bobot: xavier_uniform
Model dengan inisialisasi xavier_uniform memperoleh akurasi: 0.9109

Melatih model dengan inisialisasi bobot: xavier_normal
Model dengan inisialisasi xavier_normal memperoleh akurasi: 0.9077
```

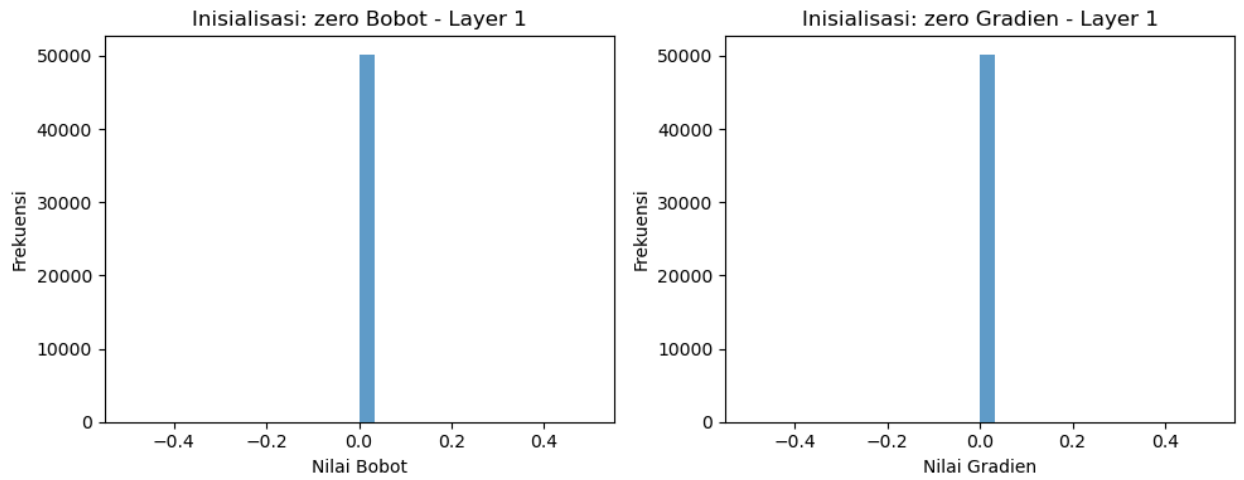
Gambar 2.2.4.1. Perbandingan Hasil Prediksi variasi inisialisasi bobot

Berikut adalah hasil perbandingan loss pelatihan untuk pengujian variasi learning rate :




Gambar 2.2.4.2. Perbandingan Loss Pelatihan



Berikut adalah Hasil Perbandingan Distribusi Bobot dan Gradien tiap layer:





Gambar 2.2.4.3. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (Zero)





Gambar 2.2.4.4. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (Zero)



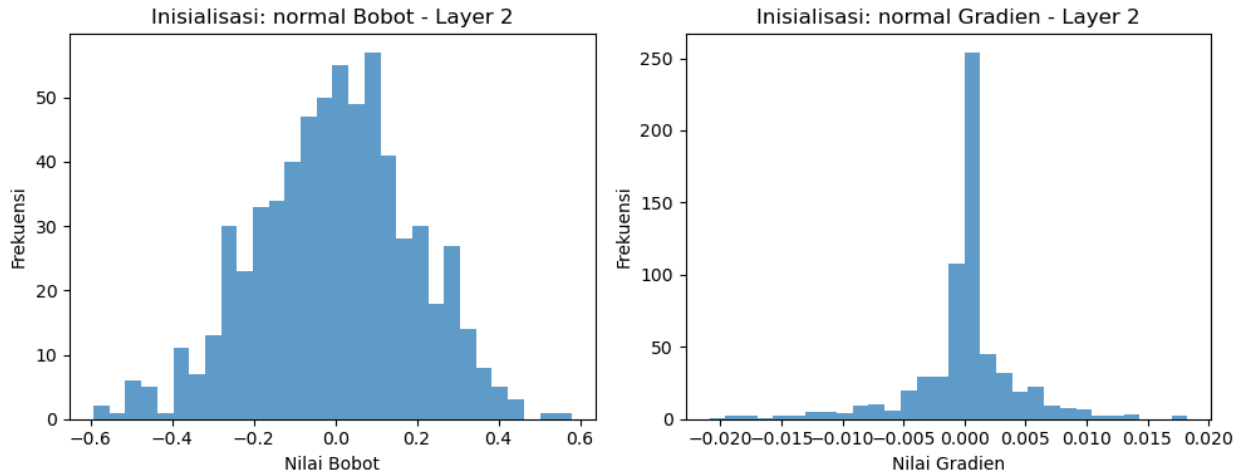
Gambar 2.2.4.5. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (Uniform)




Gambar 2.2.4.6. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (Uniform)



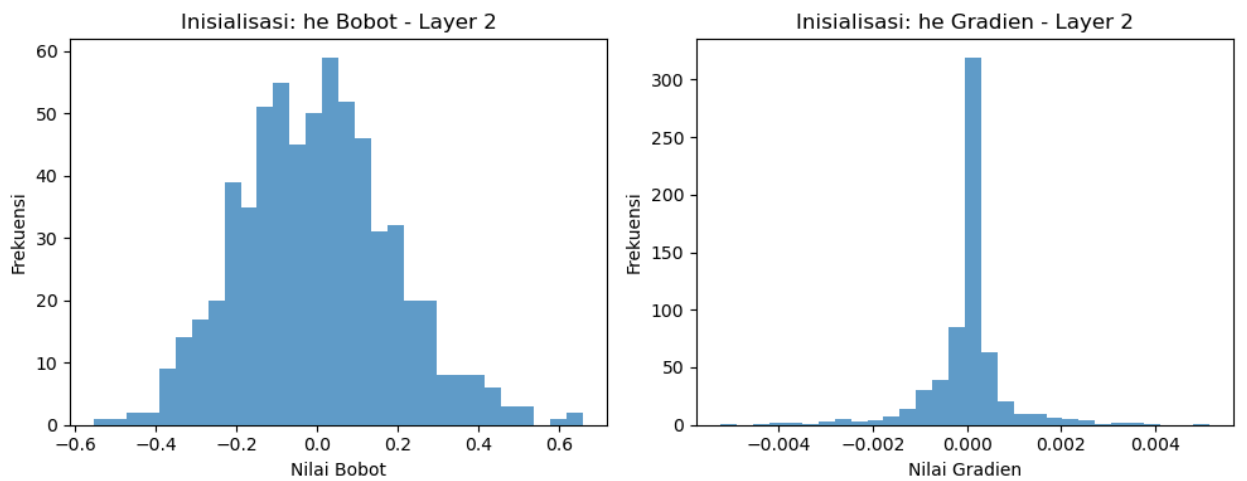
Gambar 2.2.4.7. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (normal)



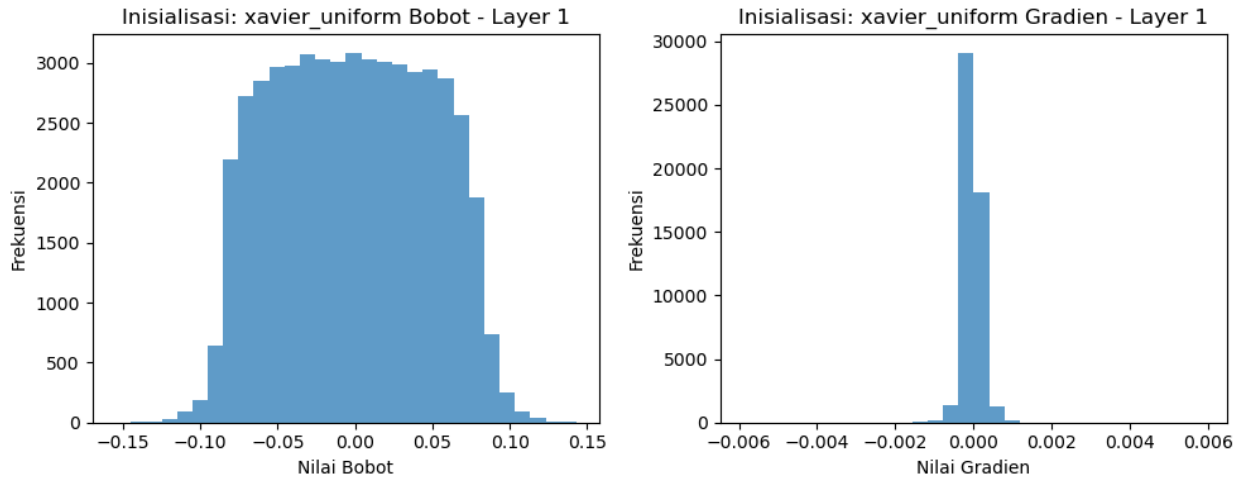
Gambar 2.2.4.8. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (normal)




Gambar 2.2.4.9. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (he)




Gambar 2.2.4.10. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (he)




Gambar 2.2.4.11. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (Xavier Uniform)



Gambar 2.2.4.12. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (Xavier Uniform)



Gambar 2.2.4.13. Perbandingan Distribusi Bobot dan Gradien pada Layer 1 (Xavier Normal)



Gambar 2.2.4.14. Perbandingan Distribusi Bobot dan Gradien pada Layer 2 (Xavier Normal)

2.2.5 Pengaruh Regularisasi

Dalam proses pelatihan jaringan saraf tiruan, sering terjadi overfitting, yaitu kondisi di mana model sangat baik dalam mempelajari data pelatihan tetapi kurang mampu menggeneralisasi ke data yang belum pernah dilihat sebelumnya. Salah satu penyebabnya adalah tingginya kompleksitas model serta nilai bobot yang besar. Untuk mengatasi masalah ini, teknik regularisasi sangat penting digunakan guna membatasi nilai bobot dan mencegah model menjadi terlalu rumit. Teknik regularisation, seperti L1 dan L2, menambahkan penalti pada fungsi loss berdasarkan besarnya bobot. Regularisasi L1 cenderung menghasilkan model dengan bobot yang lebih jarang (sparse), sedangkan regularisasi L2 membantu menjaga agar bobot tetap kecil tanpa memaksa banyak bobot menjadi nol. Dengan menerapkan teknik ini, diharapkan model tidak hanya mampu mempelajari pola dari data pelatihan, tetapi juga memiliki kemampuan generalisasi yang lebih baik pada data baru.

Implementasi regularisasi dalam model FFNN di atas dilakukan secara terintegrasi dalam proses backward propagation. Pada saat inisialisasi, model menerima parameter `reg_type` yang menentukan jenis regularisasi (L1 atau L2) serta `lambda_reg` sebagai nilai hyperparameter penalti. Selama proses perhitungan gradien, setelah gradien terhadap bobot dihitung, jika `reg_type` diatur ke L1, maka gradien tersebut ditambahkan dengan penalti berupa $(\lambda_{reg} \times \text{sign}(w))/\text{shape}(x)$ untuk setiap bobot. Penalti ini mendorong banyak bobot mendekati nol, sehingga menghasilkan model dengan bobot yang lebih jarang (sparse). Sebaliknya, jika `reg_type` diatur ke L2, gradien diperbarui dengan menambahkan $(\lambda_{reg} \times w)/\text{shape}(x)$, yang berfungsi menjaga agar nilai bobot tidak terlalu besar tanpa secara eksplisit memaksa banyak bobot menjadi nol. Dengan cara ini, pembaruan bobot selama training tidak hanya dipengaruhi oleh error yang dihitung melalui fungsi loss, tetapi juga oleh penalti regularisasi, sehingga membantu mengurangi overfitting dan meningkatkan kemampuan generalisasi model terhadap data baru.


Untuk mengevaluasi pengaruh penggunaan regularisasi, dilakukan eksperimen dengan menggunakan 3 konfigurasi model yaitu Tanpa Regularisasi, Regularisasi L1, Regularisasi L2. Metodologi eksperimen yang diterapkan meliputi:

- **Dataset:** Digunakan dataset MNIST yang berisi gambar tulisan tangan digit.
- **Data Processing:** Data fitur dinormalisasi menggunakan StandardScaler agar

setiap fitur memiliki skala yang sama. Selanjutnya, label diubah ke format one-hot encoding dengan OneHotEncoder. Dataset kemudian dibagi dengan perbandingan 80% untuk data pelatihan dan 20% untuk data pengujian.

- **Struktur Jaringan:** Pada eksperimen ini, model FFNN dibangun dengan struktur [784, 64, 64, 10], di mana 784 merupakan jumlah neuron pada layer input, 64 dan 64 adalah jumlah neuron pada hidden layer, dan 10 adalah jumlah neuron pada output layer.
- **Fungsi Aktivasi:** Fungsi aktivasi yang digunakan adalah ReLU untuk hidden layer dan softmax untuk output layer.
- **Inisiasi Bobot:** Bobot diinisiasi menggunakan metode inisiasi bobot He.
- **Perbandingan Model:** Tiga konfigurasi model dibandingkan, yaitu model tanpa *Regularisasi* (`reg_type = None`, `lambda_reg = 0`), model dengan *Regularisasi L1* (`reg_type = L1`, `lambda_reg = 0.01`) dan model dengan *Regularisasi L2* (`reg_type = L2`, `lambda_reg = 0.01`).
- **Parameter Pelatihan:** Parameter pelatihan yang digunakan meliputi batch size 32, jumlah epoch 50, dan learning rate 0.01.
- **Evaluasi Performa:** Evaluasi dilakukan dengan membandingkan grafik loss per epoch, akurasi prediksi, distribusi bobot dan gradien, serta visualisasi struktur jaringan.

Hasil Perbandingan Loss pada Pelatihan dan Validasi:



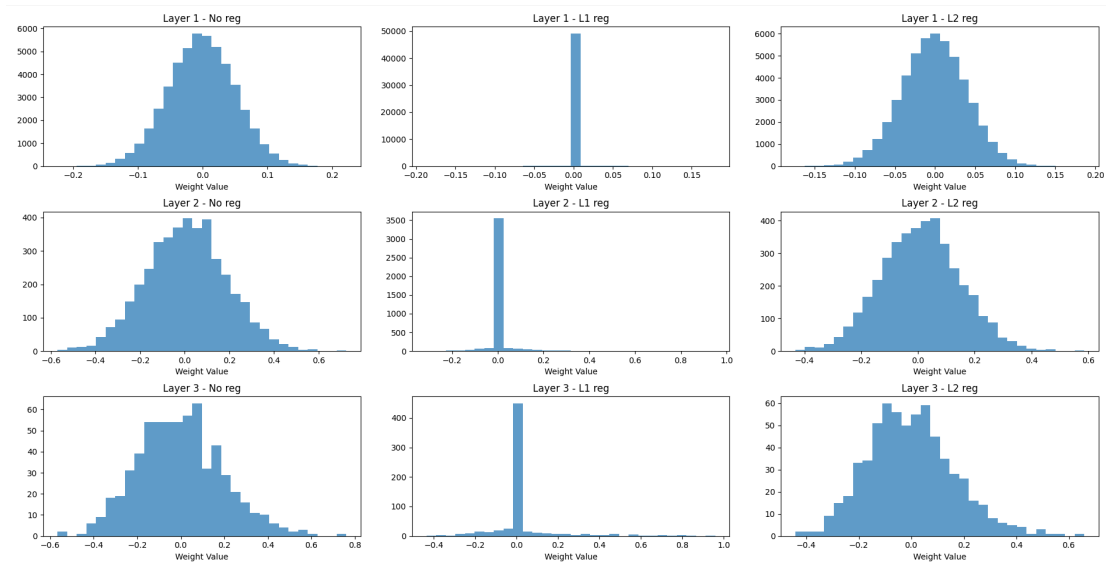
Gambar 2.2.5.1. Perbandingan Loss Pelatihan dan Validasi

Hasil Perbandingan Akurasi Hasil Prediksi:

```
Comparing prediction results:
No regularization: Accuracy = 0.9367
L1 regularization: Accuracy = 0.8714
L2 regularization: Accuracy = 0.9349
C:\Users\Tubas_1\Documents>
```

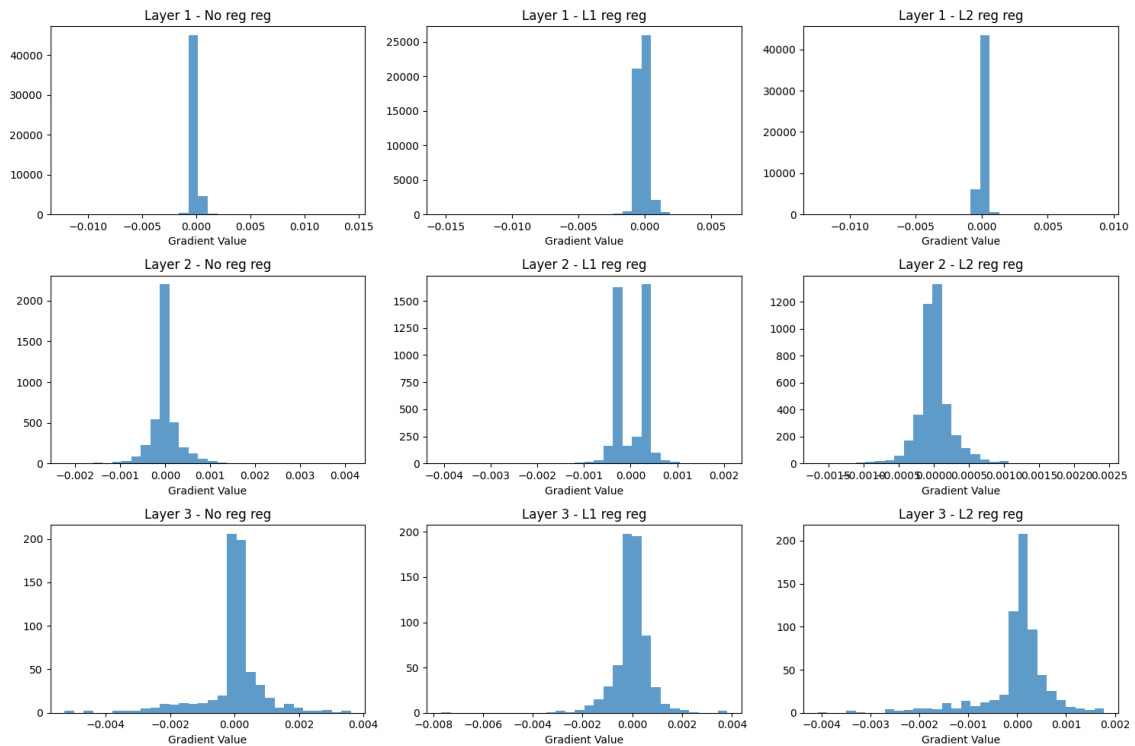
Gambar 2.2.5.2. Perbandingan Hasil Akurasi

Hasil Perbandingan bobot di setiap layer untuk ketiga model:



Gambar 2.2.5.3. Perbandingan distribusi bobot di setiap layer

Hasil Perbandingan Gradien di setiap layer untuk ketiga model:



Gambar 2.2.5.4. Perbandingan Gradien di setiap layer

Pada grafik *loss* di atas (Gambar 2.2.5.1), model tanpa regularisasi (No reg) menurun dengan cepat pada data pelatihan (*train loss*) dan tetap cukup rendah pada data validasi (*val loss*), menandakan bahwa model mampu mempelajari pola dengan efektif. Sementara itu, model dengan L1 regularisasi menampilkan *train loss* dan *val loss* yang lebih tinggi, kemungkinan karena penalti L1 menekan bobot secara agresif sehingga menurunkan kapasitas model dan memicu *underfitting*. Di sisi lain, model dengan L2 regularisasi menunjukkan penurunan *train loss* yang stabil dan *val loss* yang mendekati model tanpa regularisasi, mengindikasikan bahwa penalti L2 dapat menjaga bobot tetap kecil tanpa terlalu mengurangi fleksibilitas model. Hal ini menegaskan bahwa pemilihan jenis dan besaran penalti regularisasi harus disesuaikan dengan karakteristik data serta tujuan pelatihan agar performa model dapat dioptimalkan.

Dari segi akurasi pada data uji (Gambar 2.2.5.2), model tanpa regularisasi berhasil meraih akurasi sekitar 0,9367, disusul oleh model dengan L2 regularisasi di kisaran 0,9349, sedangkan model L1 regularisasi hanya mencapai 0,8714. Perbedaan yang cukup besar pada model L1

menunjukkan bahwa penggunaan penalti L1 yang tidak diatur dengan tepat dapat membuat model kehilangan fleksibilitasnya dalam mengenali pola.

Berdasarkan histogram bobot di setiap layer (Gambar 2.2.5.3), model tanpa regularisasi (No reg) memiliki distribusi bobot yang lebih lebar di sekitar nol, menandakan ketiadaan penalti yang membatasi nilai bobot. Pada model L1, distribusi bobot membentuk puncak tajam di sekitar nol, terutama di layer kedua dan ketiga, yang menunjukkan banyak bobot ditekan mendekati nol (*sparse*). Sementara itu, model L2 menampilkan distribusi bobot yang lebih terpusat di sekitar nol, tetapi tidak setajam L1, menandakan bahwa penalti L2 membatasi nilai bobot agar tidak terlalu besar tanpa memaksa terlalu banyak bobot menjadi nol.

Beralih ke histogram gradien (Gambar 2.2.5.4), model tanpa regularisasi (No reg) menampilkan sebaran gradien yang relatif moderat dan simetris di sekitar nol. Pada model dengan L1 regularisasi, tampak puncak tajam di sekitar nol, menandakan penalti L1 mendorong banyak gradien menuju nol sehingga bobot cenderung diperbarui secara *sparse*. Sementara itu, model L2 menampilkan sebaran gradien yang lebih sempit namun tidak seekstrem L1, mencerminkan bahwa penalti L2 menjaga nilai gradien agar tetap kecil tanpa memaksa terlalu banyak gradien menjadi nol.

Secara keseluruhan, eksperimen ini menegaskan pentingnya regularisasi dalam mengendalikan kompleksitas model. Walaupun model tanpa regularisasi dapat meraih akurasi yang tinggi, model dengan L2 regularisasi memberikan performa hampir setara dengan kestabilan yang lebih baik. Model L1 regularisasi dapat menurunkan akurasi jika penalti (λ) terlalu besar, karena menekan terlalu banyak bobot menjadi nol. Regularisasi sangat cocok untuk situasi di mana data terbatas, risiko *overfitting* tinggi, atau ketika kita menginginkan model yang lebih sederhana dan mudah diinterpretasikan (khususnya L1). Kelebihan L2 adalah kemampuannya menjaga bobot tetap kecil tanpa memaksa terlalu banyak bobot menjadi nol, sementara L1 unggul dalam mendorong *sparsity*. Namun, pemilihan dan penyesuaian *hyperparameter* λ menjadi kunci untuk menghindari *underfitting* (pada L1) atau tetap berisiko *overfitting* (jika λ terlalu kecil). Dengan demikian, diperlukan penyesuaian yang tepat agar model dapat mencapai performa optimal.

2.2.6 Pengaruh normalisasi *RMSNorm*

Normalisasi dalam jaringan saraf berperan penting dalam mengatasi masalah seperti gradien yang menghilang atau meledak selama proses pelatihan. *RMSNorm* (Root Mean Square Normalization) merupakan salah satu teknik normalisasi yang tidak bergantung pada statistik batch, sehingga cocok digunakan pada skenario dengan batch size kecil atau data streaming. Dengan menerapkan *RMSNorm*, nilai pre-aktivasi pada setiap hidden layer dinormalisasi berdasarkan nilai RMS, sehingga distribusi aktivasi menjadi lebih konsisten dan propagasi gradien pun menjadi lebih stabil. Dalam penelitian ini, *RMSNorm* diintegrasikan ke dalam model FFNN sebagai upaya untuk meningkatkan stabilitas dan kecepatan konvergensi selama training.

Dalam model FFNN yang dikembangkan, ketika opsi *RMSNorm* diaktifkan (`use_rmsnorm=True`), parameter gamma diinisialisasi untuk setiap hidden layer guna mengkalibrasi hasil normalisasi. Pada proses forward pass, nilai pre-aktivasi (z) yang dihasilkan dari operasi linier dinormalisasi dengan cara menghitung nilai akar rata-rata kuadrat (RMS) dari z —dengan tambahan epsilon untuk menjaga stabilitas numerik—kemudian membagi z dengan RMS tersebut, dan akhirnya mengalikan hasilnya dengan gamma agar skala nilai dapat disesuaikan. Selanjutnya, pada tahap backward pass, selain menghitung gradien terhadap bobot dan bias, model juga menghitung gradien untuk parameter gamma dengan memperhitungkan kontribusi nilai pre-aktivasi asli (z_{raw}) dan RMS. Dengan demikian, pembaruan parameter gamma dapat membantu menjaga kestabilan distribusi aktivasi dan gradien, yang pada akhirnya mengurangi risiko terjadinya gradien yang meledak atau menghilang, sehingga pelatihan model menjadi lebih stabil dan efisien.


Untuk mengevaluasi pengaruh penggunaan *RMSNorm*, dilakukan eksperimen dengan dua konfigurasi model, yaitu model tanpa *RMSNorm* dan model dengan *RMSNorm*. Metodologi eksperimen yang diterapkan meliputi:

- **Dataset:** Digunakan dataset MNIST yang berisi gambar tulisan tangan digit.
- **Data Processing:** Data fitur dinormalisasi menggunakan `StandardScaler` agar setiap fitur memiliki skala yang sama. Selanjutnya, label diubah ke format one-hot encoding dengan `OneHotEncoder`. Dataset kemudian dibagi dengan

perbandingan 80% untuk data pelatihan dan 20% untuk data pengujian.

- **Struktur Jaringan:** Pada eksperimen ini, model FFNN dibangun dengan struktur [784, 128, 64, 10], di mana 784 merupakan jumlah neuron pada layer input, 128 dan 64 adalah jumlah neuron pada hidden layer, dan 10 adalah jumlah neuron pada output layer.
- **Fungsi Aktivasi:** Fungsi aktivasi yang digunakan adalah ReLU untuk hidden layer dan softmax untuk output layer.
- **Inisiasi Bobot:** Bobot diinisiasi menggunakan metode inisiasi bobot He.
- **Perbandingan Model:** Dua konfigurasi model dibandingkan, yaitu model tanpa *RMSNorm* (`use_rmsnorm = False`) dan model dengan *RMSNorm* (`use_rmsnorm = True`).
- **Parameter Pelatihan:** Parameter pelatihan yang digunakan meliputi batch size 32, jumlah epoch 100, dan learning rate 0.01.
- **Evaluasi Performa:** Evaluasi dilakukan dengan membandingkan grafik loss per epoch, akurasi prediksi, distribusi bobot dan gradien, serta visualisasi struktur jaringan.

Hasil Perbandingan Loss Pelatihan dan Validasi:



Gambar 2.2.6.1. Perbandingan Loss Pelatihan dan Validasi


Hasil Perbandingan Akurasi Hasil Prediksi:

```
Perbandingan hasil prediksi:  
Tanpa RMSNorm: Accuracy = 0.9534  
Dengan RMSNorm: Accuracy = 0.9529
```

Gambar 2.2.6.2. Perbandingan Hasil Prediksi

Hasil Perbandingan Distribusi Bobot dan Gradien untuk Layer 1:


Distribusi Bobot dan Gradien untuk Layer 1



Gambar 2.2.6.3. Perbandingan Distribusi Bobot dan Gradien pada Layer 1

Hasil Perbandingan Distribusi Bobot dan Gradien untuk Layer 2:


Distribusi Bobot dan Gradien untuk Layer 2



Gambar 2.2.6.4. Perbandingan Distribusi Bobot dan Gradien pada Layer 2

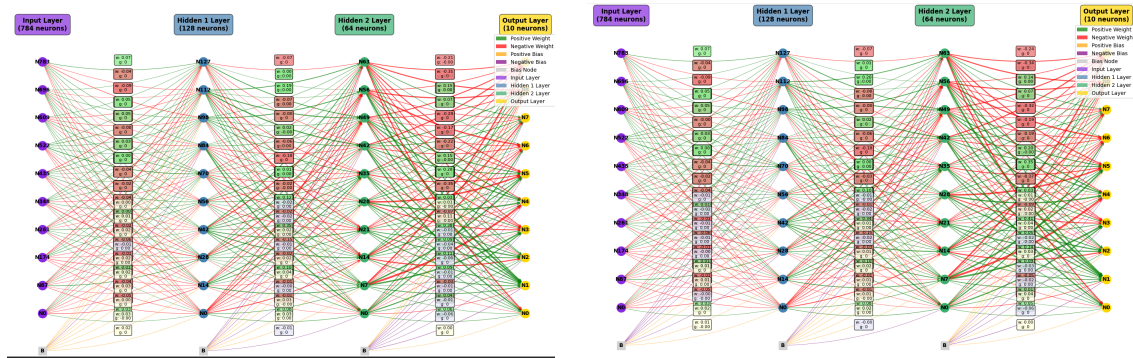
Hasil Perbandingan Distribusi Bobot dan Gradien untuk Layer 3:

Distribusi Bobot dan Gradien untuk Layer 3



Gambar 2.2.6.5. Perbandingan Distribusi Bobot dan Gradien pada Layer 3

Graf Model FFNN:



Gambar 2.2.6.6. Perbandingan Graf model FFNN tanpa RMSNorm dan dengan RMSNorm

Berdasarkan grafik *loss* pelatihan dan validasi (Gambar 2.2.6.1), kedua model—baik tanpa RMSNorm maupun dengan RMSNorm—menunjukkan pola penurunan *loss* yang serupa. Keduanya berhasil mencapai nilai *loss* yang relatif rendah pada akhir pelatihan. Hal ini menunjukkan bahwa penerapan RMSNorm tidak memberikan perbedaan signifikan dalam hal laju konvergensi maupun stabilitas *loss*, setidaknya pada konfigurasi hyperparameter dan jumlah data pelatihan yang digunakan.

Dari segi akurasi pada data uji, model tanpa RMSNorm memperoleh akurasi sekitar 0,9534, sedangkan model dengan RMSNorm memperoleh akurasi 0,9529. Perbedaan yang sangat kecil ini mengindikasikan bahwa, untuk kasus MNIST dengan *batch size* 32, RMSNorm tidak memberikan peningkatan akurasi yang berarti. Meskipun demikian, hasil ini tidak serta-merta meniadakan manfaat RMSNorm; terdapat banyak studi yang menunjukkan bahwa RMSNorm dapat memberikan stabilitas pelatihan yang lebih baik, terutama pada skenario dengan *batch size* yang sangat kecil atau pada arsitektur model yang lebih dalam.

Dari distribusi bobot dan gradien (Gambar 2.2.6.3, 2.2.6.4, dan 2.2.6.5 untuk masing-masing layer), terlihat bahwa keduanya cenderung memiliki bentuk sebaran yang mirip, terutama berbentuk hampir simetris di sekitar nilai nol. RMSNorm memang mempengaruhi perhitungan *forward pass* dan *backward pass*, namun pada dataset MNIST yang relatif sederhana, efek normalisasi tidak terlalu kontras. Perbedaan yang

lebih jelas mungkin akan terlihat pada tugas yang lebih kompleks atau ketika *batch size* sangat kecil, di mana stabilitas normalisasi akan lebih krusial.

Selain itu, visualisasi struktur jaringan (Gambar 2.2.6.6) tidak menunjukkan perbedaan yang kasatmata dari segi topologi, karena kedua model memiliki arsitektur yang sama. Perbedaan utama terletak pada parameter *gamma* yang digunakan RMSNorm untuk menyesuaikan skala aktivasi.

Secara umum, RMSNorm lebih relevan untuk membantu pelatihan tetap stabil pada arsitektur yang lebih dalam, skenario *batch size* kecil, atau data *streaming* yang tidak memungkinkan penggunaan Batch Normalization secara efektif. Dalam konteks MNIST dengan *batch size* menengah dan arsitektur yang tidak terlalu dalam, RMSNorm masih berfungsi dengan baik tetapi tidak memberikan peningkatan yang signifikan dibandingkan model tanpa normalisasi tersebut.

Dari hasil eksperimen ini, dapat disimpulkan bahwa:

1. Penerapan RMSNorm pada model FFNN dengan dataset MNIST dan *batch size* 32 tidak memberikan peningkatan akurasi yang berarti jika dibandingkan dengan model tanpa RMSNorm.
2. Distribusi bobot dan gradien pada kedua model cenderung mirip, mengindikasikan bahwa normalisasi RMSNorm tidak secara drastis mengubah sebaran parameter dalam kasus ini.
3. Walaupun pada eksperimen ini RMSNorm tidak menunjukkan perbedaan yang signifikan, metode ini tetap relevan dan dapat menjadi alternatif bagi Batch Normalization, terutama untuk kondisi *batch size* kecil atau arsitektur yang lebih dalam, di mana stabilitas dan kecepatan konvergensi menjadi lebih krusial.

2.2.7 Perbandingan dengan library sklearn

Untuk menilai performa model **FFNN** yang dikembangkan secara *custom*, dilakukan perbandingan dengan model **MLPClassifier** dari library *scikit-learn (sklearn)*. Keduanya sama-sama menggunakan parameter utama yang serupa, seperti jumlah neuron pada *hidden layer*, fungsi aktivasi ReLU, serta *learning rate* dan *batch size* yang sebanding.

Langkah Eksperimen:

1. Inisialisasi Model Custom FFNN

Model FFNN didefinisikan dengan susunan layer [784,64,10], menggunakan fungsi aktivasi ReLU di *hidden layer* dan softmax di layer output. Bobot diinisialisasi dengan metode *He initialization*. Proses pelatihan dilakukan dengan *loss* *categorical_crossentropy_loss*, menggunakan *stochastic gradient descent* (SGD) sederhana selama 20 *epoch* dengan *learning rate* sebesar 0.1 dan *batch size* 32.

2. Inisialisasi Model sklearn MLPClassifier

Model **MLPClassifier** dari *sklearn* juga dikonfigurasi dengan satu *hidden layer* berukuran 64 neuron, fungsi aktivasi ReLU, *solver* SGD, *learning_rate_init* 0.1, dan *max_iter* 20. Hal ini dilakukan untuk menjaga kesetaraan kondisi pelatihan agar hasil perbandingan menjadi lebih adil.

3. Pelatihan dan Evaluasi

- Custom FFNN:

Model custom FFNN dilatih dengan data latih (*training set*), lalu dilakukan evaluasi pada data validasi (*validation set*). Hasil pelatihan menampilkan akurasi akhir di sekitar 0,9530.

- MLPClassifier:

Model sklearn **MLPClassifier** dilatih dengan data yang sama dan dievaluasi pada data validasi. Akurasi yang diperoleh mencapai sekitar 0,9610.

```

Melatih model FFNN custom...
Akurasi FFNN custom: 0.9530
Melatih model sklearn MLPClassifier...
Akurasi sklearn MLPClassifier: 0.9610
Perbandingan prediksi (10 data pertama):
FFNN custom : [8 4 8 7 7 0 6 2 7 4]
sklearn MLP : [8 4 8 7 7 0 6 2 7 4]

```

Gambar 2.2.7.1. Hasil Perbandingan Custom FFNN dan Library Sklearn

4. Perbandingan Hasil Prediksi

Untuk memberikan gambaran lebih jelas, ditampilkan juga hasil prediksi 10 data pertama dari set validasi. Dari hasil tersebut, dapat terlihat bahwa secara umum kedua model memberikan prediksi yang serupa, meskipun terdapat beberapa perbedaan pada beberapa contoh data.

Analisis Perbandingan

Hasil menunjukkan bahwa model **MLPClassifier** memiliki akurasi yang sedikit lebih tinggi (0,9610) dibandingkan dengan model custom FFNN (0,9530). Selisih akurasi tersebut kemungkinan besar disebabkan oleh beberapa faktor, di antaranya:

- **Implementasi Optimizer:**

MLPClassifier secara default menerapkan berbagai teknik optimasi dan *parameter tuning* (misalnya, *momentum*, *learning rate schedule*, dsb.) yang mungkin lebih canggih dibandingkan implementasi SGD sederhana pada model custom FFNN.

- **Regularisation Otomatis:**

MLPClassifier secara otomatis menerapkan beberapa bentuk regularisasi (misalnya, *L2 penalty*) yang dapat membantu model menghindari *overfitting* dan meningkatkan generalisasi. Jadi meskipun di percobaan kali ini untuk *reg_type* dimatikan, namun *MLPClassifier* menerapkan regularisasi secara otomatis.

- **Hyperparameter Tuning:**

Pada *MLPClassifier*, beberapa hyperparameter dapat diatur secara otomatis atau lebih mudah dikustomisasi. Sementara itu, pada model custom, proses tuning mungkin lebih terbatas sehingga mempengaruhi performa akhir.

Sehingga meskipun pada percobaan ini sudah ditentukan parameter yang sama untuk kedua model, namun ada banyak hyperparameter lain yang bisa secara otomatis diatur oleh sklearn.

Perbandingan ini menunjukkan bahwa model **FFNN custom** memiliki performa yang kompetitif, namun masih sedikit di bawah **sklearn MLPClassifier** pada konfigurasi dasar. Meskipun demikian, hasil akurasi yang diperoleh model custom sudah tergolong tinggi dan cukup memadai untuk Training.

BAB III

KESIMPULAN DAN SARAN

3.1 Kesimpulan

Dari hasil eksperimen dan analisis yang telah dilakukan, dapat disimpulkan bahwa implementasi FFNN secara from scratch berhasil menampilkan performa yang kompetitif pada dataset MNIST. Peningkatan width dan depth memberikan kontribusi positif terhadap akurasi, meskipun peningkatan width cenderung menghasilkan kenaikan yang lebih signifikan dibandingkan dengan penambahan depth, yang diiringi dengan tantangan peningkatan kompleksitas komputasi dan potensi vanishing gradient. Eksperimen fungsi aktivasi menunjukkan bahwa fungsi non-linear seperti ReLU dan variannya (leaky_relu, ELU) mengatasi masalah vanishing gradient dengan lebih efektif dibandingkan dengan sigmoid atau tanh, yang mengalami saturasi sehingga menghambat pembelajaran. Pengaturan learning rate juga memainkan peran penting, di mana nilai yang terlalu kecil menyebabkan konvergensi lambat, sedangkan nilai yang lebih besar (misalnya 0,1) dapat mempercepat pembelajaran jika masih dalam rentang stabil. Selain itu, metode inisialisasi bobot yang tepat seperti He dan Xavier terbukti mendukung aliran gradien dan mempercepat konvergensi, sedangkan inisialisasi nol tidak mampu memecah simetri neuron. Implementasi regularisasi, baik L1 maupun L2, menunjukkan bahwa penalti yang terlalu kuat dapat menyebabkan underfitting, namun regularisasi L2 cenderung memberikan keseimbangan antara kontrol overfitting dan fleksibilitas model. Penerapan RMSNorm pada eksperimen dengan batch size sedang dan jaringan dangkal tidak memberikan peningkatan yang signifikan, namun metode ini tetap relevan untuk skenario dengan batch kecil atau arsitektur yang lebih dalam. Secara keseluruhan, perbandingan dengan library sklearn MLPClassifier juga menegaskan bahwa meskipun model custom memiliki performa yang baik, optimasi tambahan yang diterapkan oleh library tersebut (seperti penggunaan Adam dan momentum) dapat menghasilkan akurasi yang sedikit lebih tinggi.

3.2 Saran

Ke depan, disarankan agar eksperimen lebih lanjut dilakukan dengan menguji model pada dataset yang lebih kompleks dan arsitektur jaringan yang lebih dalam, sehingga manfaat teknik normalisasi seperti RMSNorm dan regularisasi lanjutan dapat lebih optimal diterapkan. Selain

itu, penerapan metode optimasi yang lebih canggih, seperti Adam atau penggunaan momentum yang lebih terintegrasi, perlu dieksplorasi untuk mempercepat konvergensi dan meningkatkan performa model. Pemanfaatan teknik hyperparameter tuning secara otomatis juga akan membantu menemukan konfigurasi optimal yang dapat mengatasi trade-off antara kompleksitas model dan risiko overfitting. Pendekatan-pendekatan ini diharapkan dapat memberikan kontribusi signifikan dalam pengembangan model FFNN yang lebih robust dan efisien di masa mendatang.

BAB IV

LAMPIRAN

4.1 Pembagian Tugas

Nama/NIM	Kontribusi
Filbert (13522021)	Laporan, L1 dan L2 Regularization, bonus activation function, eksperiment
Benardo (13522055)	Laporan, RMS Norm, bonus initialization method, eksperiment
William Glory Henderson (13522113)	Laporan, FFNN class (all method), activation and loss function, initialization method

BAB VII

REFERENSI

<https://www.geeksforgeeks.org/what-is-forward-propagation-in-neural-networks/>

<https://www.jasonosajima.com/forwardprop>

<https://www.jasonosajima.com/backprop>

https://www.cs.toronto.edu/~rgrosse/courses/csc2541_2022/tutorials/tut01.pdf